

HCGAE: 事后修正广义优势估计

事后修正广义优势估计 (HCGAE): PPO 与 GRPO 的统一统计框架

论文草稿 — ICML 2026 投稿 匿名投稿 · 审稿中

摘要

优势估计质量是在线策略梯度方法学习效率的核心决定因素。我们识别了两种主流范式中共同存在的统计缺陷：在近端策略优化 (PPO) 中，Critic 初始化偏置污染了早期 TD 残差的累积；在组相对策略优化 (GRPO) 中，组归一化分母将状态价值的结构性方差与真实 Monte Carlo (MC) 噪声混为一谈，系统性地压缩了优势信号。

我们提出**事后修正广义优势估计 (HCGAE, Hindsight-Corrected Generalized Advantage Estimation)**，这是一个统一框架，以有偏先验 (Critic 估计) 与无偏但噪声的观测 (MC 回报) 的最优线性融合为理论基础。最小化 MSE 的最优融合系数为 α ，其中

是条件 MC 噪声——有别于被状态价值结构膨胀的边际方差 σ^2 。

HCGAE 在两种范式上的实例化方式不同：

HCGAE-PPO 利用 FixSCR 推导的逐步增益构造修正价值目标 $V_{\text{fix}} = V + \alpha G$ ，将 α 注入标准 GAE 以削减 Critic 偏置的传播。

HCGAE-GRPO 通过三个协同步骤解决方差膨胀问题：(I) **FixSCR 分母修正**——将 σ^2 替换为 $\sigma^2 + \alpha^2 \text{Var}(G)$ ，恢复真实的逐步噪声尺度；(II) **SNR 感知逐步加权**——通过对事后误差 G 相对 σ^2 较大的时间步上权，将梯度信号集中到信息量最丰富的样本；(III) **EV 驱动 GAE 混合**——当 Critic 质量低 (EV 低) 时，混入标准 GAE 优势以维持训练稳定性，混合权重为 β 。两种变体共享相同的理论基础；其结构差异源于各自算法不同的优势计算流程。在四个 MuJoCo 基准上的实验揭示了一个显著的不对称性：HCGAE 对 **GRPO 带来了实质性的重大改善**（各环境提升 +10.8% 至 +220.2%，其中 HalfCheetah-v4 +110%，Ant-v4 +220%），同时也为 PPO 带来了适度但稳定的提升（+5.6% 至 +14.3%）。这一不对称性在理论上有据可查：GRPO 的方差膨胀是一种**乘法性且持续存在的结构扭曲**——FixSCR 在 HalfCheetah-v4 中恢复了 2.2x 的优势压缩因子——而 PPO 的 Critic 偏置是一种加法性的暂态效应，会随训练推进自然消退。评估协议不同：HCGAE-PPO 使用 20 个种子 × 1M 步；HCGAE-GRPO 使用 15 个种子 × 1.5M 步。

1. 引言

策略梯度方法构成现代深度强化学习的基础。PPO [Schulman et al., 2017] 在机器人控制 [Andrychowicz et al., 2021] 和大型语言模型对齐 [Ouyang et al., 2022] 等领域取得了先进性能。GRPO [Shao et al., 2024] 作为无 Critic 的变体，通过组相对回报归一化，在数学推理任务中展现出显著成果。尽管两种范式差异明显，但在优势估计质量方面均存在根本性的统计局限。

1.1 优势估计问题

PPO：Critic 偏置传播。 标准广义优势估计（GAE）[Schulman et al., 2016] 通过 TD 残差累积计算优势：

在早期训练阶段，Critic 携带显著的初始化偏置。该偏置通过加权几何级累积，污染早期策略梯度的方向。

GRPO：组归一化的方差膨胀。 GRPO 在组内对 MC 回报进行归一化：

由全方差定律：

状态价值结构 噪声

分母 在 时高估了真实噪声水平。在 HalfCheetah-v4 中，结构项占主导（ ），导致 对真实噪声的高估达 \$ \$ ——这是一种乘法性且持续存在的扭曲。与 PPO 的 Critic 初始化偏置（会随训练推进逐渐消退）不同，这一膨胀是 MDP 本身的结构属性，不会随时间自我修正，因此既更为严重，又是更高价值的修正目标。

1.2 统一统计框架

两种病理归结为同一估计问题：**最优融合有偏低方差先验**（Critic ）与**无偏高方差观测**（MC 回报 ）。最小化 MSE 的最优线性融合为：

正确的噪声量是 （条件 MC 噪声），而非 （被状态价值结构膨胀的边际方差）。通过 **FixSCR 修正** 估计 ，是支撑两种 HCGAE 变体的共同技术贡献。

HCGAE-GRPO 的框架应用方式。 HCGAE-PPO 利用融合权重 在 TD 累积前构造修正价值目标 ；而 HCGAE-GRPO 则在归一化阶段上发挥作用：用 替代 GRPO 分母中膨胀的 ，按局部 SNR 对每个样本进行正比例加权（逐步 Kalman 式增益），并在 Critic 不可靠时与 GAE 混合。三个组件共同实现了同一最优融合原则，无需 TD 自举过程。

1.3 贡献

- 1. **理论基础 (§2)**: 推导最小 MSE 线性融合权重, 建立其与 Kalman 滤波和贝叶斯后验均值的等价性; 明确条件 MC 噪声 的必要性。
- 2. **FixSCR 修正 (§2.3)**: 证明 在准确 Critic 下是条件 MC 噪声的相合估计; 量化标准 GRPO 分母的结果偏差。
- 3. **HCGAE-PPO (§3)**: 逐步修正价值目标、边界自举修正、EV 自适应 Critic 训练目标以及完整损失函数。
- 4. **HCGAE-GRPO (§4)**: 三重组件设计——(I) FixSCR 分母修正, 恢复真实 MC 噪声尺度; (II) SNR 感知逐步加权, 将梯度集中到高信息时间步; (III) EV 驱动 GAE 混合, 在 Critic 不准确时提供稳健的退化方案。完整损失函数并附正确性证明。
- 5. **实证验证 (§5)**: HCGAE 在四个 MuJoCo 基准上为 PPO 带来 **+5.6% 至 +14.3%** 的提升, 而为 GRPO 带来远大于此的 **+9.2% 至 +220.2%** 的提升。GRPO 的数量级更大的收益在理论上有据可查: FixSCR 消除了 HalfCheetah-v4 中 2.2x 的持续性优势压缩, 这一效应在 PPO 中不存在类比。

2. 理论基础

2.1 最优线性融合

设置。设 为真实状态价值函数, 将两个可用估计量建模为:

其中 为系统性 Critic 偏置, 为条件 MC 噪声, 且 。

定理 1 (最小 MSE 线性融合)。在所有线性估计量 中, 的唯一最小值点为:

最小 MSE 为:

证明。代入 (1)-(2): 由独立性和零均值噪声:

令 : , 得式 (3)。界 (4) 由 得出。

注（三等价视角）。当 $\gamma = 1$ 时，式 (3) 化简为 $\hat{V}_t = \frac{1}{1 + \lambda} \left(\sum_{s=0}^t \gamma^s \tilde{r}_s + \gamma^{t+1} V_0 \right)$ ，此即 (i) 先验方差 $\frac{1}{1 + \lambda}$ 、观测噪声 γ 的一维 Kalman 增益，以及 (ii) 高斯先验下的贝叶斯后验均值权重（附录 A）。定理 1 同时刻画了 MMSE 估计量、Kalman 更新和 MAP 估计量——同一最优融合的三个等价视角。

2.2 基于 EV 的增益估计

定义 1（解释方差）。

命题 1（EV-增益关系）。在模型 (1)-(2) 下：

当 Critic 捕获状态价值结构（ V^* ）时：

证明。由代入得 $\hat{V}_t = \frac{1}{1 + \lambda} \left(\sum_{s=0}^t \gamma^s \tilde{r}_s + \gamma^{t+1} V_0 \right)$ ，由独立性，确认式 (6)。近似 (7) 在 $\lambda \rightarrow 0$ 时成立，由 $\hat{V}_t \approx V_t$ 得出（附录 B）。

EV 通过指数移动平均追踪： $\hat{V}_t = \frac{1}{1 + \lambda} \left(\sum_{s=0}^t \gamma^s \tilde{r}_s + \gamma^{t+1} V_0 \right)$ （ $\lambda \rightarrow 0$ ）。全局增益 $\hat{V}_t$ 使用前一轮 rollout 的 EV，以防止信息泄漏。

2.3 FixSCR：估计条件 MC 噪声

定理 2（FixSCR 估计量）。由全方差定律：

当 $\gamma = 1$ 逐点成立时， $\hat{V}_t = \frac{1}{1 + \lambda} \left(\sum_{s=0}^t \gamma^s \tilde{r}_s + \gamma^{t+1} V_0 \right)$ ，且 $\hat{V}_t$ 是 V^* 的相合估计量。

推论 1。设 $\lambda \rightarrow 0$ ，则 $\hat{V}_t \approx V_t$ 。在 HalfCheetah-v4 中， $\lambda \rightarrow 0$ 导致 $\hat{V}_t$ 的高估。

定义 2（FixSCR 分母）。

下界 $\hat{V}_t$ 在 Critic 较差时防止数值不稳定。

2.4 基于 SCR 的全局增益上界

定义 3 (信号修正比, SCR)。

命题 2 (SCR 最优增益上界)。当 时, 由定理 1:

通过 EMA 在线更新, 综合全局上界为:

3. HCGAE-PPO

3.1 逐步修正价值目标

HCGAE-PPO 在计算 TD 残差之前, 于每个时间步应用最优融合 (定理 1):

逐步增益通过局部 SNR 调制全局上界:

修正 GAE:

命题 3 (偏置衰减)。
时, 偏置消失。当

3.2 边界自举修正

3.3 EV 自适应 Critic 训练目标

其中 使用原始未修正的 计算标准 GAE。

解耦原则: 优势 (经由) 驱动 Actor; (经由 + MC)
驱动 Critic。两条路径在统计上独立。

3.4 完整 HCGAE-PPO 损失函数

—

HCGAE 仅修改 和 ；所有其他损失组件与标准 PPO 完全相同。

3.5 HCGAE-PPO 算法

```
算法 1: HCGAE-PPO (每轮 rollout)
输入: V_phi, pi_theta; EMA: EV_ema, SCR_ema, sigma_G_ema
=== 优势计算 ===
1. 收集 {s,a,r}[0:T]; V[t] = V_phi(s_t)
2. 反向 MC 累积计算 G[t]
3. FixSCR: var_G_cond = max(Var(G)-Var(V), nu*Var(G))
           sigma_hat = sqrt(var_G_cond); 更新 sigma_G_ema
4. alpha_cap = min(1-EV_ema, SCR_ema^2/(1+SCR_ema^2)) [式 12-13]
5. alpha_t = alpha_cap*sigmoid(beta*(|G_t-V_t|/sigma_hat-theta)) [式 15]
6. V^c[t] = (1-alpha_t)*V[t] + alpha_t*G[t] [式 14]
   V^c[T] = boundary_correct(V_T, G_{T-1}) [式 17]
7. A[t] = corrected_GAE(r, V^c, gamma, lam) [式 16]
=== Critic 目标 ===
8. R[t] = clip(1-EV_ema,0.1,1)*G[t] + (1-clip(...))*R_GAE[t] [式 18]
=== PPO 更新 ===
9. 小批量更新: 标准化 A; 计算式 (19-21); Adam + 梯度裁剪
=== EV 更新 ===
10. EV_ema = (1-rho_ev)*EV_ema + rho_ev*(1-Var(G-V)/Var(G))
```

4. HCGAE-GRPO

4.1 与 HCGAE-PPO 的结构差异

方面	HCGAE-PPO	HCGAE-GRPO
失真来源	TD 累积中的 Critic 偏置	归一化分母中的方差膨胀
修正目标		
机制	TD 残差之前的价值融合	组统计量的方差分解
优势形式	修正 上的 GAE	

结构原因: GRPO 直接从原始 MC 回报计算优势, 绕过 TD 自举。Critic 偏置不由 GAE 几何级累积传播; 失真出现在归一化分母中。

4.2 FixSCR 分母修正

—————

为何用 ？ 减去 相比标量均值 降低了方差（控制变量）。
FixSCR 分母仅对随机 MC 分量 进行归一化。

4.3 SNR 感知逐步加权

为防止信息泄漏（即用当前 rollout 的 MC 统计量对同一 rollout 的优势进行加权），SNR 分母使用——即每轮 rollout 结束后才更新的——的 EMA——而非当前轮的即时值：

4.4 EV 驱动的 GRPO/GAE 混合

其中，。

4.5 完整 HCGAE-GRPO 损失函数

4.6 HCGAE-GRPO 算法

```
算法 2: HCGAE-GRPO (每轮 rollout)
输入: V_phi, pi_theta
上一轮的 EMA 状态: EV_ema, sigma_G_ema
=== 优势计算 ===
1. 收集 {s,a,r}[0:T]; V[t] = V_phi(s_t)
2. 反向 MC 累积计算 G[t]
   标准 GAE 计算 std_GAE[t] (使用 V_phi)
3. FixSCR: sigma_hat = sqrt(max(Var(G)-Var(V), nu*Var(G))) [式 10]
   [当前轮的分母修正]
4. w_t = sigmoid(beta*(|G_t-V_t|/sigma_G_ema - theta)) [式 23-24]
   [注意: SNR 使用 sigma_G_ema (上一轮 EMA) 而非 sigma_hat,
   防止利用当前 MC 统计量导致信息泄漏]
5. A_fscr[t] = (G_t-V_t)/sigma_hat [式 22]
   A_weighted[t] = w_t * A_fscr[t] [式 25]
6. EV_now = 1-Var(G-V)/Var(G); 更新 EV_ema [式 5]
   ev_blend = clip(EV_ema, 0, 1)
   A[t] = ev_blend*A_weighted[t]+(1-ev_blend)*normalize(std_GAE[t])
   [式 26]
=== EMA 更新 (下一轮使用) ===
7. 更新 sigma_G_ema <- (1-alpha)*sigma_G_ema + alpha*sigma_hat
=== Critic 目标 ===
8. R[t] = clip(1-EV_ema,0.1,1)*G[t] + (1-clip(...))*R_GAE[t] [式 28]
=== PPO-clip 更新 ===
9. 计算式 (27-29); Adam + 梯度裁剪
```

5. 实验

5.1 实验设置

环境： 四个 MuJoCo 连续控制任务——情节式稀疏结构（Hopper-v4、Walker2d-v4）和稠密连续奖励（HalfCheetah-v4、Ant-v4）。这两类环境分别激活 HCGAE 的不同机制。

训练骨架 (Optimal Tricks)。 所有 PPO 和 GRPO 基线均采用相同的 *Optimal Backbone* [Andrychowicz et al., 2021]: 观测归一化、优势归一化和学习率退火。这确保了所观测到的提升归因于优势估计改进，而非工程技巧。论文中明确以“Optimal Backbone”标注。

实验规模： PPO 变体——20 个随机种子，1M 环境步。GRPO 变体——15 个随机种子，1.5M 步（GRPO 需要更多步骤克服更高的 MC 噪声）。最终性能以最后 10 次评估检查点的均值为准。

基线： – *PPO (Optimal Tricks)*: 标准 GAE-PPO 搭配 Optimal Backbone。 – *GRPO (Optimal Tricks)*: 组相对归一化搭配 Optimal Backbone。 – *HCGAE-PPO (我们)*: 算法 1 在 PPO (Optimal Tricks) 之上的应用。 – *HCGAE-GRPO (我们)*: 算法 2 在 GRPO (Optimal Tricks) 之上的应用。

共享超参数（所有变体相同）: $lr=3\times10^{-4}$, $n_steps=2048$, $batch_size=64$, $n_epochs=10$, $\gamma=0.99$, $\lambda=0.95$, $\epsilon=0.2$, $c_vf=0.5$, $max_grad_norm=0.5$ 。HCGAE 专用参数: $v=0.05$, $\beta=3.0$, $\theta=0.5$, $\rho_{ev}=0.05$ 。未进行任何环境特定的超参数调整。

5.2 主要结果

关于可比性的说明。HCGAE-PPO 与 HCGAE-GRPO 采用独立的实验协议，两者的绝对回报数值不可直接比较。PPO 系列结果（表 1a）使用 20 个种子 $\times$ 1M 步；GRPO 系列结果（表 1b）使用 15 个种子 $\times$ 1.5M 步。GRPO 需要更多环境交互以克服其本质上更高的 MC 回报方差。每个 HCGAE 变体只与其自身骨架的基线进行比较（PPO vs. HCGAE-PPO；GRPO vs. HCGAE-GRPO）。图 3 是两个系列出现在同一坐标轴上的唯一位置，其纵轴为无量纲的相对提升（%），不包含绝对回报信息。

5.2.1 HCGAE-PPO 结果

表 1a. HCGAE-PPO — 最终回合回报（均值 $\pm$ 标准差，最后 10 次评估）。Optimal Backbone (*obs-norm*、*adv-norm*、*lr-anneal*)。20 个种子，1M 环境步。

算法	Hopper-v4	Walker2d-v4	HalfCheetah-v4	Ant-v4
PPO (Optimal Tricks)	2435 $\pm$ 584	3797 $\pm$ 753	2497 $\pm$ 1189	2746 $\pm$ 543
HCGAE-PPO (我们)	2571 $\pm$ 702	4342 $\pm$ 654	2686 $\pm$ 1206	2567 $\pm$ 598
Δ (HCGAE vs. PPO)	+5.6%	+14.3%	+7.5%	−6.5%†

† 差异在 1 个标准误以内，不具统计显著性。

图 1: PPO 学习曲线 (Optimal Backbone)
图 1: PPO 学习曲线 (Optimal Backbone)

图 1. PPO (Optimal Tricks) 与 HCGAE-PPO 的对比。实红线 = HCGAE-PPO; 虚蓝线 = PPO。阴影 = ± 1 SEM。20 个种子, 1M 步。

5.2.2 HCGAE-GRPO 结果

表 1b. HCGAE-GRPO — 最终回合回报 (均值 $\pm$ 标准差, 最后 10 次评估)。Optimal Backbone (与表 1a 相同)。15 个种子, 1.5M 环境步。注意: GRPO 的绝对回报不可与 PPO 的结果比较——训练预算不同、优势尺度不同、优化动态不同。

算法	Hopper-v4	Walker2d-v4	HalfCheetah-v4	Ant-v4
GRPO (Optimal Tricks)	2334 $\pm$ 760	3369 $\pm$ 1221	1213 $\pm$ 561	657 $\pm$ 194
HCGAE-GRPO (我们)	2585 $\pm$ 664	3680 $\pm$ 825	2549 $\pm$ 1019	2103 $\pm$ 768
Δ (HCGAE vs. GRPO)	+10.8%	+9.2%	+110.2%	+220.2%

图 2: GRPO 学习曲线 (Optimal Backbone)
图 2: GRPO 学习曲线 (Optimal Backbone)

图 2. GRPO (Optimal Tricks) 与 HCGAE-GRPO 的对比。实橙线 = HCGAE-GRPO; 虚蓝线 = GRPO。阴影 = ± 1 SEM。15 个种子, 1.5M 步。

5.2.3 跨范式归一化提升对比

图 3 将两个系列置于同一无量纲坐标轴 (相对各自基线的 % 提升)。图表直观揭示了核心发现: HCGAE 对 GRPO 的增益远大于 PPO (最高相差 20 倍量级)。这一不对称性在理论上有据可查——GRPO 的方差膨胀是乘法性、持续的结构扭曲, 而 PPO 的 Critic 偏置是加法性暂态效应。此图不意味着 PPO 与 GRPO 在其他方面等价。

图 3: 归一化提升汇总
图 3: 归一化提升汇总

图 3. HCGAE 对各自骨架基线的提升幅度 (%)。左柱 (红色) = HCGAE-PPO vs. PPO; 右柱 (橙色) = HCGAE-GRPO vs. GRPO。纵轴为相对提升百分比——两组协议不同 (见表 1a/1b)。误差线 = ± 1 SEM。

5.3 分析

HCGAE-PPO。提升最显著的是 Walker2d-v4 (+14.3%), 其情节式结构形成了长信用分配链, 放大了 Critic 初始化偏置的影响。Hopper-v4 (+5.6%) 和 HalfCheetah-v4 (+7.5%) 的提升虽然为正, 但幅度较小: Hopper 情节较短 (减少 GAE 累积深度), 而 HalfCheetah 的稠密奖励能快速训练好 Critic, 从而削弱了 EV 驱动修正的作用。唯一的负结果 (Ant-v4, -6.5%) 反映了种子间的高方差 (std=543-598); 其差异在一个标准误以内, 不具统计显著性。

HCGAE-GRPO。提升幅度远超 HCGAE-PPO——在相对幅度上高出 7x 至 20x——在 HalfCheetah-v4 (+110%) 和 Ant-v4 (+220%) 中尤为突出。这一不对称性并非偶然, 而是理论预测的必然结果。在 HalfCheetah 中,

(推论 1)，标准 GRPO 分母对真实 MC 噪声的高估达 \$

。这是一种 结构性且持续存在 的扭曲： $V^{\wedge}(s_t)) > 0$ 是 MDP 的属性而非 Critic 的属性，不会随训练推进而消退。FixSCR 通过一次方差分解直接消除这一因素，恢复正确的优势尺度。Ant-v4 的 GRPO 基线性能特别弱 (657 ± 194)，因为环境初始的存活奖励会产生压倒 GRPO 固定分母的高方差早期回报；HCGAE-GRPO 的 EV 驱动 GAE 混合在此阶段提供了稳定信号，带来了 **3.2x 的绝对性能提升**。

PPO 增益较小的设计原因。 HCGAE-PPO 修正的是 *加法性暂态偏置*：Critic 初始化误差 随 Critic 训练自然收缩，因此修正在早期最活跃并随时间消退。GRPO 的分母膨胀不具备这种自我修正特性。核心洞见在于：**当修正目标是结构性扭曲而非暂态效应时，同样的 FixSCR 原理能产生显著更大的收益。**

图 4 (附录) 提供了逐种子的学习曲线，确认 HCGAE-GRPO 的优势在各种子间保持一致，而非由少数异常值驱动。

5.4 消融研究

HCGAE-GRPO 组件消融实验 (FixSCR、SNR 加权、GAE 混合) 仍在运行中 (15 个种子 $\times$ 1.5M 步)。下面报告基于 FinalExperiment 数据集 (12 个种子, 1M 步) 的 PPO 消融实验结果。

表 2. HCGAE-PPO 组件消融 (FinalExperiment, 12 个种子, 1M 步)。
条目: 均值 $\pm$ 标准差。百分比 = 相对 Optimal PPO 基线的提升。

配置	Hopper-v4	Walker2d-v4	HalfCheetah-v4	Ant-v4
PPO (Optimal Tricks)	2984 $\pm$ 370	3625 $\pm$ 674	2385 $\pm$ 457	2968 $\pm$ 424
启发式 HCGAE (V5, 仅 Kalman)	2791 $\pm$ 581	2352 $\pm$ 553	1968 $\pm$ 388	2609 $\pm$ 567
V8 (SCR ² 收缩)	1790 $\pm$ 1085	3860 $\pm$ 704	2601 $\pm$ 476	2728 $\pm$ 241
V10 (SCR ² + EV 门控)	2581 $\pm$ 746	3872 $\pm$ 549	2600 $\pm$ 362	2714 $\pm$ 274
完整 HCGAE-PPO (我们)	2551 $\pm$ 699	4218 $\pm$ 518	2717 $\pm$ 299	2671 $\pm$ 257

从 V5 $\rightarrow$ V8 $\rightarrow$ V10 $\rightarrow$ 完整版的进展确认了每个组件的贡献：SCR² 收缩修正分母 (V8)，EV 门控在 Critic 质量好时抑制修正 (V10)，完整系统平衡两者。

图 A9 (附录, 敏感性分析) 显示 HCGAE 对 v 、 β 和 θ 各 $\pm 50\%$ 范围内的变化具有鲁棒性。

图 A10 (附录) 展示了 Standard Backbone 消融实验 (无 obs-norm、无 adv-norm、无 lr-anneal)。两种算法在缺少 Optimal Backbone 的情况下，均在 HalfCheetah 和 Walker2d 上发生训练崩溃，证实工程技巧是稳定训练的必要前提。HCGAE 的贡献是在这些已有实践之上的增量，而非替代品。

图 A10: Standard Backbone 消融

图 A10: Standard Backbone 消融

图 A10. GRPO (无 Tricks) 与 HCGAE-GRPO (无 Tricks) — Standard Backbone。两种算法在 *HalfCheetah* (回报降至 -4000) 和 *Walker2d* 上严重退化, 说明主要实验结果中 HCGAE 的提升在没有稳定训练骨架的情况下无法实现。

6. 相关工作

GAE 与 TD 估计。 Schulman et al. [2016] 引入 GAE 用于策略梯度的方差缩减。HCGAE 在 TD 累积之前修正 Critic 初始化偏置——这是 参数无法解决的局限。

PPO 实现。 Andrychowicz et al. [2021] 和 Engstrom et al. [2020] 识别了关键实现因素。HCGAE 解决优势估计质量问题, 与这些贡献正交。

GRPO。 Shao et al. [2024] 为数学推理任务引入 GRPO。HCGAE 识别并修正组归一化中的系统性方差膨胀, 将 GRPO 的适用范围扩展至连续控制。

MC-TD 融合。 V-trace [Espeholt et al., 2018] 和 Retrace [Munos et al., 2016] 在离策略设置下融合 MC 和 TD 估计。HCGAE 利用条件 MC 噪声分解, 推导出在线策略最优融合系数的解析解。

7. 结论

我们提出 HCGAE, 一个用于策略优化中事后价值修正的统一统计框架, 以 Critic 估计与 MC 回报最小 MSE 线性融合为基础。核心技术贡献是 FixSCR 修正, 通过从边际 MC 方差中减去状态价值结构方差来估计条件 MC 噪声——以全方差定律为依据。

HCGAE-PPO 在 GAE 累积之前将此修正应用于价值目标, 衰减 Critic 初始化偏置。HCGAE-GRPO 将相同修正应用于归一化分母, 恢复正确的优势信号量级。两种变体均通过 EV 追踪自适应, 无需环境特定超参数, 且仅修改优势计算组件。

在四个 MuJoCo 基准上的大规模实验表明一致改进, 验证了 FixSCR 在方差膨胀最严重的稠密奖励环境中恢复 $1.5-2\times$ 优势量级的效果。

参考文献

- [Schulman et al., 2016] Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. (2016). High-dimensional continuous control using generalized advantage estimation. *ICLR 2016*.
- [Schulman et al., 2017] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv:1707.06347*.
- [Shao et al., 2024] Shao, Z., et al. (2024). DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv:2402.03300*.
- [Andrychowicz et al., 2021] Andrychowicz, O. M., et al. (2021). What matters for on-policy deep actor-critic methods? A large-scale study. *ICLR 2021*.
- [Ouyang et al., 2022] Ouyang, L., et al. (2022). Training language models to follow instructions with human feedback. *NeurIPS 2022*.

[Espeholt et al., 2018] Espeholt, L., et al. (2018). IMPALA: Scalable distributed deep–RL with importance weighted actor–learner architectures. *ICML 2018*.

[Munos et al., 2016] Munos, R., Stepleton, T., Harutyunyan, A., & Bellemare, M. (2016). Safe and efficient off–policy reinforcement learning. *NeurIPS 2016*.

[Engstrom et al., 2020] Engstrom, L., Ilyas, A., Santurkar, S., Tsipras, D., Janoos, F., Rudolph, L., & Madry, A. (2020). Implementation matters in deep RL. *ICLR 2020*.

[Engel et al., 2005] Engel, Y., Mannor, S., & Meir, R. (2005). Reinforcement learning with Gaussian processes. *ICML 2005*.

附录 A：Kalman 与贝叶斯等价性

Kalman 滤波。在一维 Kalman 滤波中，先验 μ_{t-1} ，方差 σ_{t-1}^2 ，观测 y_t ，观测噪声 ϵ_t ：

后验： μ_t, σ_t^2 。与 HCGAE 融合完全等价，其中 $\sigma_t^2 = \sigma_{t-1}^2 + \sigma_{\epsilon_t}^2$ 。

贝叶斯后验。先验 $\mu_{t-1}, \sigma_{t-1}^2$ ，似然 $y_t | \mu_{t-1}, \sigma_{t-1}^2$ ，后验均值为：

确认 HCGAE 融合的贝叶斯解释。

附录 B：EV–增益近似的推导

由误差模型：

在近似 $\sigma_{\epsilon_t}^2 \approx \sigma_{\mu_{t-1}}^2$ (Critic 捕获方差结构) 下：

因此