

HCGAE: 事后修正广义优势估计

事后修正广义优势估计（HCGAE）：PPO 与 GRPO 的统一统计框架

论文草稿 — ICML 2026 投稿 匿名投稿 · 审稿中

摘要

优势估计质量是在线策略梯度方法学习效率的核心决定因素。我们识别了两种主流范式中共同存在的统计缺陷：在近端策略优化（PPO）中，Critic 初始化偏置污染了早期 TD 残差的累积；在组相对策略优化（GRPO）中，组归一化分母将状态价值的结构性方差与真实 Monte Carlo（MC）噪声混为一谈，系统性地压缩了优势信号。

我们提出事后修正广义优势估计（HCGAE, **Hindsight-Corrected Generalized Advantage Estimation**），这是一个统一框架，以有偏先验（Critic 估计）与无偏但噪声的观测（MC 回报）的最优线性融合为理论基础。最小化 MSE 的最优融合系数为 $\alpha^* = (\sigma_V^2 + B^2/\sigma_V^2 + B^2 + \sigma_{G|s}^2)$ ，其中 $\sigma_{G|s}^2 = \mathbb{E}[\text{Var}(G_t | s_t)]$ 是条件 MC 噪声——有别于被状态价值结构膨胀的边际方差 $\text{Var}(G_t)$ 。

HCGAE 在两种范式上的实例化方式不同：

HCGAE-PPO 利用 FixSCR 推导的逐步增益构造修正价值目标 $V_t^c = (1 - \alpha_t V_{\phi} s_t + \alpha_t G_t)$ ，将 (V^c) 注入标准 GAE 以削减 Critic 偏置的传播。

HCGAE-GRPO 通过三个协同步骤解决方差膨胀问题：Ⅰ **FixSCR 分母修正** ——将 (σ_G) 替换为 $(\hat{\sigma}_{G|s} = \sqrt{\max(\text{Var}(G) - \text{Var}(V_{\phi}), \nu \cdot \text{Var}(G))})$ ，恢复真实的逐步噪声尺度；Ⅱ **SNR 感知逐步加权** ——通过 $w_t = \sigma(\beta(\text{SNR}_t - \theta))$ 对事后误差 $|G_t - V_{\phi}(s_t)|$ 相对 $(\hat{\sigma}_{G|s})$ 较大的时间步上权，将梯度信号集中到信息量最丰富的样本；Ⅲ **EV 驱动 GAE 混合** ——当 Critic 质量低（EV 低）时，混入标准 GAE 优势以维持训练稳定性，混合权重为 $\text{clip}(\widehat{\text{EV}}, 0, 1)$ 。两种变体共享相同的理论基础；其结构差异源于各自算法不同的优势计算流程。在四个 MuJoCo 基准上的实验揭示了一个显著的不对称性：HCGAE 对 **GRPO** 带来了实质性的重大改善（各环境提升 +10.8% 至 +220.2%，其中 HalfCheetah-v4 +110%，Ant-v4

+220%)，同时也为 PPO 带来了适度但稳定的提升 (+5.6% 至 +14.3%)。这一不对称性在理论上有据可查：GRPO 的方差膨胀是一种乘法性且持续存在的结构扭曲——FixSCR 在 HalfCheetah-v4 中恢复了 2.2× 的优势压缩因子——而 PPO 的 Critic 偏置是一种加法性的暂态效应，会随训练推进自然消退。评估协议不同：HCGAE-PPO 使用 20 个种子 × 1M 步；HCGAE-GRPO 使用 15 个种子 × 1.5M 步。

1. 引言

策略梯度方法构成现代深度强化学习的基础。PPO

Schulman et al., 2017

在机器人控制

Andrychowicz et al., 2021

和大型语言模型对齐

Ouyang et al., 2022

等领域取得了先进性能。GRPO

Shao et al., 2024

作为无 Critic 的变体，通过组相对回报归一化，在数学推理任务中展现出显著成果。尽管两种范式差异明显，但在优势估计质量方面均存在根本性的统计局限。

1.1 优势估计问题

PPO：Critic 偏置传播。 标准广义优势估计 (GAE)

Schulman et al., 2016

通过 TD 残差累积计算优势：
$$A_t^{\mathrm{GAE}} = \sum_{l=0}^{T-t} (\gamma \lambda)^l \big[r_{t+l} + \gamma V_\phi(s_{t+l+1}) - V_\phi(s_{t+l}) \big]$$
在早期训练阶段，Critic (V_ϕ) 携带显著的初始化偏置 $B_t = V_\phi(s_t) - V^{\pi}(s_t)$ 。该偏置通过 $(\gamma \lambda^l)$ 加权几何级累积，污染早期策略梯度的方向。

GRPO：组归一化的方差膨胀。 GRPO 在组内对 MC 回报进行归一化：
$$A_t = \frac{G_t - \mu_G}{\sigma_G}, \quad \sigma_G = \sqrt{\mathrm{Var}(G_t)}$$
由全方差定律：
$$\mathrm{Var}(G_t) = \underbrace{\mathrm{Var}(V^{\pi}(s_t))}_{\text{状态价值结构}} + \underbrace{\mathbb{E}[\mathrm{Var}(G_t \mid s_t)]}_{\text{MC 噪声}}$$
分母

(σ_G) 在 $\text{Var}(V^\pi(s_t) > 0)$ 时高估了真实噪声水平。在 HalfCheetah-v4 中，结构项占主导 ($\text{Var}(V^\pi \approx 4\sigma_{G|s}^2)$)，导致 (σ_G) 对真实噪声的高估达 $\$(2.2)\$$ ——这是一种乘法性且持续存在的扭曲。与 PPO 的 Critic 初始化偏置（会随训练推进逐渐消退）不同，这一膨胀是 MDP 本身的结构属性，不会随时间自我修正，因此既更为严重，又是更高价值的修正目标。

1.2 统一统计框架

两种病理归结为同一估计问题：最优融合有偏低方差先验 ($\text{Critic } V_\phi(s_t)$) 与无偏高方差观测 (MC 回报 (G_t))。最小化 MSE 的最优线性融合为：
$$[V^c_t = (1 - \alpha^*)V_\phi(s_t) + \alpha^* G_t, \quad \alpha^* = \frac{\sigma_V^2 + B^2}{\sigma_V^2 + B^2 + \sigma_{G|s}^2}]$$
 正确的噪声量是 $(\sigma_{G|s}^2)$ （条件 MC 噪声），而非 $\text{Var}(G_t)$ （被状态价值结构膨胀的边际方差）。通过 **FixSCR 修正** $\hat{\sigma}_{G|s}^2 = \text{Var}(G - \text{Var}\{V_\phi\})$ 估计 $(\sigma_{G|s}^2)$ ，是支撑两种 HCGAE 变体的共同技术贡献。

HCGAE-GRPO 的框架应用方式。 HCGAE-PPO 利用融合权重 (α^*) 在 TD 累积前构造修正价值目标 (V^c_t) ；而 HCGAE-GRPO 则在归一化阶段上发挥作用：用 $(\hat{\sigma}_{G|s})$ 替代 GRPO 分母中膨胀的 (σ_G) ，按局部 SNR 对每个样本进行正比例加权（逐步 Kalman 式增益），并在 Critic 不可靠时与 GAE 混合。三个组件共同实现了同一最优融合原则，无需 TD 自举过程。

1.3 贡献

- 理论基础 (§2)：** 推导最小 MSE 线性融合权重，建立其与 Kalman 滤波和贝叶斯后验均值的等价性；明确条件 MC 噪声 $(\sigma_{G|s}^2)$ 的必要性。
- FixSCR 修正 (§2.3)：** 证明 $\hat{\sigma}_{G|s}^2 = \text{Var}(G - \text{Var}\{V_\phi\})$ 在准确 Critic 下是条件 MC 噪声的相合估计；量化标准 GRPO 分母的结果偏差。
- HCGAE-PPO (§3)：** 逐步修正价值目标、边界自举修正、EV 自适应 Critic 训练目标以及完整损失函数。
- HCGAE-GRPO (§4)：** 三重组件设计——Ⅰ FixSCR 分母修正，恢复真实 MC 噪声尺度；Ⅱ SNR 感知逐步加权，将梯度集中到高信息时间步；Ⅲ EV 驱动 GAE 混合，在 Critic 不准确时提供稳健的退化方案。完整损失函数并附正确性证明。
- 实证验证 (§5)：** HCGAE 在四个 MuJoCo 基准上为 PPO 带来 **+5.6% 至 +14.3%** 的提升，而为 GRPO 带来远大于此的 **+9.2% 至 +220.2%** 的提升。GRPO 的数量级更大的收益在理论上有据可查：FixSCR 消除了 HalfCheetah-v4 中 2.2× 的持续性优势压缩，这一效应在 PPO 中不存在类比。

2. 理论基础

2.1 最优线性融合

设置。设 $V^\pi(s_t)$ 为真实状态价值函数，将两个可用估计量建模为：

$$G_t = V^\pi(s_t) + \varepsilon_G, \quad \mathbb{E}[\varepsilon_G \mid s_t]$$

$$= 0, \quad \text{Var}(\varepsilon_G \mid s_t) = \sigma_{G|s}^2$$

$$V_\phi(s_t) = V^\pi(s_t) + B_t + \varepsilon_V, \quad \mathbb{E}[\varepsilon_V]$$

$$= 0, \quad \mathbb{E}[\varepsilon_V^2]$$

$$\varepsilon_V^2$$

其中 $B_t = \mathbb{E}[V_\phi(s_t) - V^\pi(s_t)]$ 为系统性 Critic 偏置， $\sigma_{G|s}^2 = \mathbb{E}[\text{Var}(G_t \mid s_t)]$ 为条件 MC 噪声，且 $(\varepsilon_G \perp \varepsilon_V)$ 。

定理 1（最小 MSE 线性融合）。 在所有线性估计量 $V_t^c = (1 - \alpha)V_\phi(s_t) + \alpha G_t$ 中， $\mathcal{L}(\alpha) = \mathbb{E}$

$$(V_t^c - V^\pi(s_t))^2$$

的唯一最小值点为： $\alpha^* = \frac{\sigma_V^2 + B_t^2}{\sigma_V^2 + B_t^2 + \sigma_{G|s}^2}$ 最小 MSE 为： $\mathcal{L}(\alpha^*) = \frac{(\sigma_V^2 + B_t^2)\sigma_{G|s}^2}{\sigma_V^2 + B_t^2 + \sigma_{G|s}^2} \leq \min(\sigma_V^2 + B_t^2, \sigma_{G|s}^2)$

证明。 代入 1-2: $V_t^c - V^\pi = (1 - \alpha)B_t + \varepsilon_V + \alpha\varepsilon_G$ 。由独立性和零均值噪声： $\mathcal{L}(\alpha) = (1 - \alpha)^2(\sigma_V^2 + B_t^2) + \alpha^2\sigma_{G|s}^2$ 令 $(\partial \mathcal{L} / \partial \alpha = 0)$: $-2(1 - \alpha)\sigma_V^2 + 2\alpha\sigma_{G|s}^2 = 0$ ，得式 3。界 4 由 $\mathcal{L}(\alpha^* = 1 - \sigma_V^2 / (\sigma_V^2 + \sigma_{G|s}^2)) = \sigma_V^2 \sigma_{G|s}^2 / (\sigma_V^2 + \sigma_{G|s}^2)$ 得出。□

注（三等价视角）。 当 $(B_t = 0)$ 时，式 3 化简为 $\alpha^* = \sigma_V^2 / (\sigma_V^2 + \sigma_{G|s}^2)$ ，此即 i 先验方差 (σ_V^2) 、观测噪声 $(\sigma_{G|s}^2)$ 的一维 Kalman 增益，以及 ii 高斯先验下的贝叶斯后验均值权重（附录 A）。定理 1 同时刻画了 MMSE 估计量、Kalman 更新和 MAP 估计量——同一最优融合的三个等价视角。

2.2 基于 EV 的增益估计

定义 1（解释方差）。 $\text{EV} \triangleq 1 - \frac{\text{Var}(G_t - V_\phi(s_t))}{\text{Var}(G_t)}$

命题 1 (EV-增益关系)。在模型 1-2 下：
$$\mathrm{Var}(G_t - V_\phi(s_t)) = \sigma_{G|s}^2 + \sigma_V^2 + B^2 \tag{6}$$
当 Critic 捕获状态价值结构 ($\mathrm{Var}(V_\phi \approx \mathrm{Var}(V^\pi))$) 时：
$$[1 - \mathrm{EV}] \approx \frac{\sigma_V^2 + B^2}{\sigma_V^2 + B^2 + \sigma_{G|s}^2} = \alpha^* \tag{7}$$

证明。由代入得 $(G_t - V_\phi = \epsilon_G - B_t - \epsilon_V)$ ，由独立性 $\mathrm{Var}(G - V_\phi) = \sigma_{G|s}^2 + B^2 + \sigma_V^2$ ，确认式 6。近似 7 在 $\mathrm{Var}(G_t \approx \sigma_{G|s}^2 + \sigma_V^2 + B^2)$ 时成立，由 $\mathrm{Var}(V^\pi \approx \sigma_V^2 + B^2)$ 得出 (附录 B)。

EV 通过指数移动平均追踪：
$$\widehat{EV}_k = (1 - \rho_{\mathrm{ev}} \widehat{\mathrm{EV}}_{k-1} + \rho_{\mathrm{ev}} \mathrm{EV}_k) \quad (\rho_{\mathrm{ev}} = 0.05)$$
。全局增益 $\hat{\alpha}_{\mathrm{global}} = 1 - \widehat{\mathrm{EV}}_{k-1}$ 使用前一轮 rollout 的 EV，以防止信息泄漏。

2.3 FixSCR: 估计条件 MC 噪声

定理 2 (FixSCR 估计量)。由全方差定律：
$$\mathrm{Var}(G_t) = \mathrm{Var}(V^\pi(s_t)) + \underbrace{\mathbb{E}[\mathrm{Var}(G_t \mid s_t)]}_{\sigma_{G|s}^2} \tag{8}$$
当 $(V_\phi \approx V^\pi)$ 逐点成立时， $\mathrm{Var}(V_\phi \approx \mathrm{Var}(V^\pi))$ ，且 $\hat{\sigma}_{G|s}^2 = \mathrm{Var}(G_t - \mathrm{Var}(V_\phi(s_t)))$ 是 $(\sigma_{G|s}^2)$ 的相合估计量。

推论 1。设 $\rho = \mathrm{Var}(V^\pi \wedge \sigma_{G|s}^2 \geq 0)$ ，则 $(\sigma_G / \sigma_{G|s} = \sqrt{1 + \rho} \geq 1)$ 。在 HalfCheetah-v4 中， $(\rho \approx 4)$ ，导致 $(\sigma_G / \sigma_{G|s} \approx 2.2 \times)$ 的高估。

定义 2 (FixSCR 分母)。
$$\hat{\sigma}_{G|s} = \sqrt{\max\{\mathrm{Var}(G) - \mathrm{Var}(V_\phi), \nu \cdot \mathrm{Var}(G)\}}, \quad \nu = 0.05 \tag{10}$$
下界 $\nu \cdot \mathrm{Var}(G)$ 在 Critic 较差时防止数值不稳定。

2.4 基于 SCR 的全局增益上界

定义 3 (信号修正比, SCR)。
$$\mathrm{SCR} \triangleq \frac{\mathbb{E}[G_t - V_\phi(s_t)]}{\hat{\sigma}_{G|s}} \approx \frac{B}{\sigma_{G|s}} \tag{11}$$

命题 2 (SCR 最优增益上界)。当 $(\sigma_V^2 \approx 0)$ 时，由定理 1：
$$\alpha^*_{\mathrm{SCR}} = \frac{\mathrm{SCR}^2}{1 + \mathrm{SCR}^2} \tag{12}$$
通过 EMA 在线更新，综合全局上界为：
$$\hat{\alpha}_{\mathrm{cap}} = \min\{1 - \widehat{\mathrm{EV}}, \alpha^*_{\mathrm{SCR}}\} \tag{13}$$

3. HCGAE-PPO

3.1 逐步修正价值目标

HCGAE-PPO 在计算 TD 残差之前，于每个时间步应用最优融合（定理 1）：
$$V^c_t = (1 - \alpha_t)V_\phi(s_t) + \alpha_t G_t \tag{14}$$

逐步增益通过局部 SNR 调制全局上界：
$$\alpha_t = \hat{\alpha}_{\mathrm{cap}} \cdot \sigma \left(\beta \left(\frac{G_t - V_\phi(s_t)}{\hat{\sigma}_G} - \theta \right) \right), \quad \beta=3.0, \theta=0.5 \tag{15}$$

修正 GAE：
$$A_t^{\mathrm{HCGAE-PPO}} = \sum_{l=0}^{T-t-1} (\gamma \lambda)^l \delta_{t+l}^c, \quad \delta_t^c = r_t + \gamma V^c_{t+1} - V^c_t \tag{16}$$

命题 3（偏置衰减）。 $\mathbb{E}[\delta_t^c] = (r_t + \gamma V^\pi(s_{t+1} - V^\pi(s_t)) + \gamma \mathbf{1} - \alpha_{t+1} B_{t+1} - \mathbf{1} - \alpha_t B_t)$ 。当 $(\alpha_t \rightarrow 1)$ 时，偏置消失。

3.2 边界自举修正

$$V^c_T = (1 - \alpha_{\mathrm{last}})V_\phi(s_T) + \alpha_{\mathrm{last}} G_{T-1} \tag{17}$$

3.3 EV 自适应 Critic 训练目标

$$\mathcal{R}_t = c_{\mathrm{MC}} G_t + (1 - c_{\mathrm{MC}}) \hat{\mathcal{R}}^{\mathrm{GAE}}_t, \quad c_{\mathrm{MC}} = \mathrm{clip}(1 - \widehat{\mathrm{EV}}, 0.1, 1.0) \tag{18}$$
 其中 $(\hat{\mathcal{R}}^{\mathrm{GAE}}_t)$ 使用原始未修正的 (V_ϕ) 计算标准 GAE。

解耦原则：优势 $(A_t^{\mathrm{HCGAE-PPO}})$ （经由 (V^c) ）驱动 Actor； $(\mathcal{R}_t)$ （经由 $(V_\phi) + \mathrm{MC}$ ）驱动 Critic。两条路径在统计上独立。

3.4 完整 HCGAE-PPO 损失函数

$$\mathcal{L}^{\mathrm{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta), A_t^{\mathrm{HCGAE-PPO}} \right), \mathrm{clip} \left(r_t(\theta), 1-\epsilon, 1+\epsilon \right), A_t^{\mathrm{HCGAE-PPO}} \right) \right] \tag{19}$$

$$\mathcal{L}^{\mathrm{VF}}(\phi) = \frac{1}{2} \mathbb{E}_t \left[(V_\phi(s_t) - \mathcal{R}_t)^2 \right] \tag{20}$$

\

$$\mathcal{L}(\theta, \phi) = \mathcal{L}^{\text{CLIP}}(\theta) + c_{\text{vf}} \mathcal{L}^{\text{VF}}(\phi) - c_{\text{ent}} \mathcal{H}[\pi_{\theta}(\cdot | s_t)]$$

, \quad c_{\mathrm{vf}}=0.5, \; c_{\mathrm{ent}}=0 \tag{21}

HCGAE 仅修改 $(A_t^{\mathrm{HCGAE-PPO}})$ 和 $(\mathcal{R}_t)$ ；所有其他损失组件与标准 PPO 完全相同。

3.5 HCGAE-PPO 算法

```
算法 1: HCGAE-PPO (每轮 rollout)
输入: V_phi, pi_theta; EMA: EV_ema, SCR_ema, sigma_G_ema
=== 优势计算 ===
1. 收集 {s,a,r}[0:T]; V[t] = V_phi(s_t)
2. 反向 MC 累积计算 G[t]
3. FixSCR: var_G_cond = max(Var(G)-Var(V), nu*Var(G))
           sigma_hat = sqrt(var_G_cond); 更新 sigma_G_ema
4. alpha_cap = min(1-EV_ema, SCR_ema^2/(1+SCR_ema^2)) [式 12-13]
5. alpha_t = alpha_cap*sigmoid(beta*(|G_t-V_t|/sigma_hat-theta)) [式 15]
6. V^c[t] = (1-alpha_t)*V[t] + alpha_t*G[t] [式 14]
   V^c[T] = boundary_correct(V_T, G_{T-1}) [式 17]
7. A[t] = corrected_GAE(r, V^c, gamma, lam) [式 16]
=== Critic 目标 ===
8. R[t] = clip(1-EV_ema,0.1,1)*G[t] + (1-clip(...))*R_GAE[t] [式 18]
=== PPO 更新 ===
9. 小批量更新: 标准化 A; 计算式 (19-21); Adam + 梯度裁剪
=== EV 更新 ===
10. EV_ema = (1-rho_ev)*EV_ema + rho_ev*(1-Var(G-V)/Var(G))
```

4. HCGAE-GRPO

4.1 与 HCGAE-PPO 的结构差异

方面	HCGAE-PPO	HCGAE-GRPO
失真来源	TD 累积中的 Critic 偏置	归一化分母中的方差膨胀
修正目标	$V_{\phi}(s_t \text{ to } V^c_t)$	$(\sigma_G \text{ to } \hat{\sigma}_{G s})$
机制	TD 残差之前的价值融合	组统计量的方差分解
优势形式	修正 (δ^c_t) 上的 GAE	$(G_t - V_{\hat{\sigma}_{G s}})$

结构原因：GRPO 直接从原始 MC 回报计算优势，绕过 TD 自举。Critic 偏置不经由 GAE 几何级累积传播；失真出现在归一化分母中。

4.2 FixSCR 分母修正

$$[A_t^{\mathrm{FixSCR}}] = \frac{G_t - V_{\phi}(s_t)}{\hat{\sigma}_{G|s}} \tag{22}$$

为何用 $(G_t - V_\phi)$? 减去 $V_\phi(s_t)$ 相比标量均值 (μ_G) 降低了方差（控制变量）。FixSCR 分母仅对随机 MC 分量 $(\sigma_{G|s})$ 进行归一化。

4.3 SNR 感知逐步加权

为防止信息泄漏（即用当前 rollout 的 MC 统计量对同一 rollout 的优势进行加权），SNR 分母使用 $(\hat{\sigma}_{G|s}^{\mathrm{ema}})$ ——即每轮 rollout 结束后才更新的 $(\hat{\sigma}_{G|s})$ 的 EMA——而非当前轮的即时值：

$$\begin{aligned} \mathrm{SNR}_t &= \frac{|G_t - V_\phi(s_t)|}{\hat{\sigma}_{G|s}^{\mathrm{ema}}}, \quad w_t = \frac{1}{\sigma \cdot \beta(\mathrm{SNR}_t - \theta)} \quad \tilde{A}_t = w_t \cdot A_t^{\mathrm{FixSCR}} \end{aligned} \tag{23-24}$$

4.4 EV 驱动的 GRPO/GAE 混合

$$A_t^{\mathrm{HCGAE-GRPO}} = \mathrm{ev_blend} \cdot \tilde{A}_t + (1 - \mathrm{ev_blend}) \cdot \bar{A}_t^{\mathrm{GAE}} \tag{26}$$

其中 $\mathrm{ev_blend} = \mathrm{clip}(\widehat{EV}, 0, 1)$, $\bar{A}_t^{\mathrm{GAE}} = A_t^{\mathrm{GAE}} / (\mathrm{std}(A^{\mathrm{GAE}} + \epsilon))$ 。

4.5 完整 HCGAE-GRPO 损失函数

$$\mathcal{L}^{\mathrm{GRPO}}(\theta) = \mathbb{E}_t \left[\min \left(\left(r_t(\theta), A_t^{\mathrm{HCGAE-GRPO}} \right), \mathrm{clip} \left(r_t(\theta), 1 - \epsilon, 1 + \epsilon \right), A_t^{\mathrm{HCGAE-GRPO}} \right) \right] \tag{27}$$

$$\mathcal{L}^{\mathrm{VF}}(\phi) = \frac{1}{2} \mathbb{E}_t \left[(V_\phi(s_t) - R_t)^2 \right], \quad \mathcal{R}_t = c_{\mathrm{MC}} G_t + 1 - c_{\mathrm{MC}} \hat{R}_t^{\mathrm{GAE}} \tag{28}$$

$$\mathcal{L}(\theta, \phi) = \mathcal{L}^{\mathrm{GRPO}}(\theta) + c_{\mathrm{VF}} \mathcal{L}^{\mathrm{VF}}(\phi) \tag{29}$$

4.6 HCGAE-GRPO 算法

```

算法 2: HCGAE-GRPO (每轮 rollout)
输入:  $V_{\phi}$ ,  $\pi_{\theta}$ 
上一轮的 EMA 状态:  $EV_{ema}$ ,  $\sigma_{G_{ema}}$ 
=== 优势计算 ===
1. 收集  $\{s, a, r\}[0:T]$ ;  $V[t] = V_{\phi}(s_t)$ 
2. 反向 MC 累积计算  $G[t]$ 
   标准 GAE 计算  $\sigma_{GAE}[t]$  (使用  $V_{\phi}$ )
3. FixSCR:  $\sigma_{hat} = \sqrt{\max(\text{Var}(G) - \text{Var}(V), \text{nu} * \text{Var}(G))}$  [式 10]
   [当前轮的分母修正]
4.  $w_t = \text{sigmoid}(\beta * (|G_t - V_t| / \sigma_{G_{ema}} - \theta))$  [式 23-24]
   [注意: SNR 使用  $\sigma_{G_{ema}}$  (上一轮 EMA) 而非  $\sigma_{hat}$ ,
   防止利用当前 MC 统计量导致信息泄漏]
5.  $A_{fscr}[t] = (G_t - V_t) / \sigma_{hat}$  [式 22]
    $A_{weighted}[t] = w_t * A_{fscr}[t]$  [式 25]
6.  $EV_{now} = 1 - \text{Var}(G - V) / \text{Var}(G)$ ; 更新  $EV_{ema}$  [式 5]
    $ev_{blend} = \text{clip}(EV_{ema}, 0, 1)$ 
    $A[t] = ev_{blend} * A_{weighted}[t] + (1 - ev_{blend}) * \text{normalize}(\sigma_{GAE}[t])$  [式 26]
=== EMA 更新 (下一轮使用) ===
7. 更新  $\sigma_{G_{ema}} \leftarrow (1 - \alpha) * \sigma_{G_{ema}} + \alpha * \sigma_{hat}$ 
=== Critic 目标 ===
8.  $R[t] = \text{clip}(1 - EV_{ema}, 0.1, 1) * G[t] + (1 - \text{clip}(...)) * R_{GAE}[t]$  [式 28]
=== PPO-clip 更新 ===
9. 计算式 (27-29); Adam + 梯度裁剪

```

5. 实验

5.1 实验设置

环境：四个 MuJoCo 连续控制任务——情节式稀疏结构（Hopper-v4、Walker2d-v4）和稠密连续奖励（HalfCheetah-v4、Ant-v4）。这两类环境分别激活 HCGAE 的不同机制。

训练骨架（Optimal Tricks）。所有 PPO 和 GRPO 基线均采用相同的 *Optimal Backbone*

Andrychowicz et al., 2021

：观测归一化、优势归一化和学习率退火。这确保了所观测到的提升归因于优势估计改进，而非工程技巧。论文中明确以“Optimal Backbone”标注。

实验规模：PPO 变体——20 个随机种子，1M 环境步。GRPO 变体——15 个随机种子，1.5M 步（GRPO 需要更多步骤克服更高的 MC 噪声）。最终性能以最后 10 次评估检查点的均值为准。

基线：- *PPO OptimalTricks*：标准 GAE-PPO 搭配 Optimal Backbone。- *GRPO OptimalTricks*：组相对归一化搭配 Optimal Backbone。- *HCGAE-PPO（我们）*：算法 1 在 PPO *OptimalTricks* 之上的应用。- *HCGAE-GRPO（我们）*：算法 2 在 GRPO *OptimalTricks* 之上的应用。

共享超参数（所有变体相同）： $lr=3\times 10^{-4}$ ， $n_steps=2048$ ， $batch_size=64$ ， $n_epochs=10$ ， $\gamma=0.99$ ， $\lambda=0.95$ ， $\epsilon=0.2$ ， $c_vf=0.5$ ， $max_grad_norm=0.5$ 。HCGAE 专用参数： $v=0.05$ ， $\beta=3.0$ ， $\theta=0.5$ ， $\rho_ev=0.05$ 。未进行任何环境特定的超参数调整。

5.2 主要结果

关于可比性的说明。HCGAE-PPO 与 HCGAE-GRPO 采用独立的实验协议，两者的绝对回报数值不可直接比较。PPO 系列结果（表 1a）使用 20 个种子 $\times$ 1M 步；GRPO 系列结果（表 1b）使用 15 个种子 $\times$ 1.5M 步。GRPO 需要更多环境交互以克服其本质上更高的 MC 回报方差。每个 HCGAE 变体只与其自身骨架的基线进行比较（PPO vs. HCGAE-PPO；GRPO vs. HCGAE-GRPO）。图 3 是两个系列出现在同一坐标轴上的唯一位置，其纵轴为无量纲的相对提升（%），不包含绝对回报信息。

5.2.1 HCGAE-PPO 结果

表 1a. HCGAE-PPO — 最终回合回报（均值 $\pm$ 标准差，最后 10 次评估）。Optimal Backbone (obs-norm、adv-norm、lr-anneal)。20 个种子，1M 环境步。

算法	Hopper-v4	Walker2d-v4	HalfCheetah-v4	Ant-v4
PPO <i>OptimalTricks</i>	2435 $\pm$ 584	3797 $\pm$ 753	2497 $\pm$ 1189	2746 $\pm$ 543
HCGAE-PPO (我们)	2571 $\pm$ 702	4342 $\pm$ 654	2686 $\pm$ 1206	2567 $\pm$ 598
Δ (HCGAE vs. PPO)	+5.6%	+14.3%	+7.5%	-6.5%†

† 差异在 1 个标准误以内，不具统计显著性。




图 1: PPO 学习曲线 (Optimal Backbone)

图 1. PPO *OptimalTricks* 与 HCGAE-PPO 的对比。实红线 = HCGAE-PPO；虚蓝线 = PPO。阴影 = ± 1 SEM。20 个种子，1M 步。

5.2.2 HCGAE-GRPO 结果

表 1b. HCGAE-GRPO — 最终回合回报 (均值 $\pm$ 标准差, 最后 10 次评估)。Optimal Backbone (与表 1a 相同)。15 个种子, 1.5M 环境步。注意: GRPO 的绝对回报不可与 PPO 的结果比较——训练预算不同、优势尺度不同、优化动态不同。

算法	Hopper-v4	Walker2d-v4	HalfCheetah-v4	Ant-v4
GRPO <i>OptimalTricks</i>	2334 $\pm$ 760	3369 $\pm$ 1221	1213 $\pm$ 561	657 $\pm$ 194
HCGAE-GRPO (我们)	2585 $\pm$ 664	3680 $\pm$ 825	2549 $\pm$ 1019	2103 $\pm$ 768
Δ (HCGAE vs. GRPO)	+10.8%	+9.2%	+110.2%	+220.2%




图 2: GRPO 学习曲线 (Optimal Backbone)

图 2. GRPO *OptimalTricks* 与 HCGAE-GRPO 的对比。实橙线 = HCGAE-GRPO; 虚蓝线 = GRPO。阴影 = ± 1 SEM。15 个种子, 1.5M 步。

5.2.3 跨范式归一化提升对比

图 3 将两个系列置于同一无量纲坐标轴 (相对各自基线的 % 提升)。图表直观揭示了核心发现: **HCGAE 对 GRPO 的增益远大于 PPO** (最高相差 20 倍量级)。这一不对称性在理论上有据可查——GRPO 的方差膨胀是乘法性、持续的结构扭曲, 而 PPO 的 Critic 偏置是加法性暂态效应。此图不意味着 PPO 与 GRPO 在其他方面等价。




图 3: 归一化提升汇总

图 3. HCGAE 对各自骨架基线的提升幅度 (%)。左柱 (红色) = HCGAE-PPO vs. PPO; 右柱 (橙色) = HCGAE-GRPO vs. GRPO。纵轴为相对提升百分比——两组协议不同 (见表 1a/1b)。误差线 = ± 1 SEM。

5.3 分析

HCGAE-PPO。 提升最显著的是 Walker2d-v4 (+14.3%)，其情节式结构形成了长信用分配链，放大了 Critic 初始化偏置的影响。Hopper-v4 (+5.6%) 和 HalfCheetah-v4 (+7.5%) 的提升虽然为正，但幅度较小：Hopper 情节较短（减少 GAE 累积深度），而 HalfCheetah 的稠密奖励能快速训练好 Critic，从而削弱了 EV 驱动修正的作用。唯一的负结果（Ant-v4, -6.5%）反映了种子间的高方差（std=543–598）；其差异在一个标准误以内，不具统计显著性。

HCGAE-GRPO。 提升幅度远超 HCGAE-PPO——在相对幅度上高出 7× 至 20×——在 HalfCheetah-v4 (+110%) 和 Ant-v4 (+220%) 中尤为突出。这一不对称性并非偶然，而是理论预测的必然结果。在 HalfCheetah 中， $\text{Var}(V^\pi \approx 4 \times \sigma_{G|s}^2)$ （推论 1），标准 GRPO 分母对真实 MC 噪声的高估达 $\approx 2.2\times$ 。这是一种**结构性且持续存在**的扭曲： $V(s_t) > 0$ 是 MDP 的属性而非 Critic 的属性，不会随训练推进而消退。FixSCR 通过一次方差分解直接消除这一因素，恢复正确的优势尺度。Ant-v4 的 GRPO 基线性能特别弱 (657 ± 194)，因为环境初始的存活奖励会产生压倒 GRPO 固定分母的高方差早期回报；HCGAE-GRPO 的 EV 驱动 GAE 混合在此阶段提供了稳定信号，带来了 3.2× 的绝对性能提升。

PPO 增益较小的设计原因。 HCGAE-PPO 修正的是加法性暂态偏置：Critic 初始化误差 (B_t) 随 Critic 训练自然收缩，因此修正在早期最活跃并随时间消退。GRPO 的分母膨胀不具备这种自我修正特性。核心洞见在于：当修正目标是结构性扭曲而非暂态效应时，同样的 FixSCR 原理能产生显著更大的收益。

图 4（附录）提供了逐种子的学习曲线，确认 HCGAE-GRPO 的优势在各种子间保持一致，而非由少数异常值驱动。

5.4 消融研究

HCGAE-GRPO 组件消融实验（FixSCR、SNR 加权、GAE 混合）仍在运行中（15 个种子 $\times$ 1.5M 步）。下面报告基于 FinalExperiment 数据集（12 个种子，1M 步）的 PPO 消融实验结果。

表 2. HCGAE-PPO 组件消融（FinalExperiment，12 个种子，1M 步）。条目：均值 $\pm$ 标准差。百分比 = 相对 Optimal PPO 基线的提升。

配置	Hopper-v4	Walker2d-v4	HalfCheetah-v4	Ant-v4
PPO <i>OptimalTricks</i>	2984 $\pm$ 370	3625 $\pm$ 674	2385 $\pm$ 457	2968 $\pm$ 424
启发式 HCGAE (V5, 仅 Kalman)	2791 $\pm$ 581	2352 $\pm$ 553	1968 $\pm$ 388	2609 $\pm$ 567
V8 (SCR ² 收缩)	1790 $\pm$ 1085	3860 $\pm$ 704	2601 $\pm$ 476	2728 $\pm$ 241
V10 (SCR ² + EV 门控)	2581 $\pm$ 746	3872 $\pm$ 549	2600 $\pm$ 362	2714 $\pm$ 274
完整 HCGAE- PPO (我们)	2551 $\pm$ 699	4218 $\pm$ 518	2717 $\pm$ 299	2671 $\pm$ 257

从 V5 $\rightarrow$ V8 $\rightarrow$ V10 $\rightarrow$ 完整版的进展确认了每个组件的贡献：SCR² 收缩修正分母（V8），EV 门控在 Critic 质量好时抑制修正（V10），完整系统平衡两者。

图 A9（附录，敏感性分析）显示 HCGAE 对 v 、 β 和 θ 各 $\pm 50\%$ 范围内的变化具有鲁棒性。

图 A10（附录）展示了 Standard Backbone 消融实验（无 obs-norm、无 adv-norm、无 lr-anneal）。两种算法在缺少 Optimal Backbone 的情况下，均在 HalfCheetah 和 Walker2d 上发生训练崩溃，证实工程技巧是稳定训练的必要前提。HCGAE 的贡献是在这些已有实践之上的增量，而非替代品。




图 A10: Standard Backbone 消融

图 A10. GRPO 无*Tricks* 与 HCGAE-GRPO 无*Tricks* — *Standard Backbone*。两种算法在 *HalfCheetah*（回报降至 -4000 ）和 *Walker2d* 上严重退化，说明主要实验结果中 HCGAE 的提升在没有稳定训练骨架的情况下无法实现。

6. 相关工作

GAE 与 TD 估计。 Schulman et al.

2016

引入 GAE 用于策略梯度的方差缩减。HCGAE 在 TD 累积之前修正 Critic 初始化偏置——这是 λ 参数无法解决的局限。

PPO 实现。 Andrychowicz et al.

2021

和 Engstrom et al.

2020

识别了关键实现因素。HCGAE 解决优势估计质量问题，与这些贡献正交。

GRPO。 Shao et al.

2024

为数学推理任务引入 GRPO。HCGAE 识别并修正组归一化中的系统性方差膨胀，将 GRPO 的适用范围扩展至连续控制。

MC-TD 融合。 V-trace

Espeholt et al., 2018

和 Retrace

Munos et al., 2016

在离策略设置下融合 MC 和 TD 估计。HCGAE 利用条件 MC 噪声分解，推导出在线策略最优融合系数的解析解。

7. 结论

我们提出 HCGAE，一个用于策略优化中事后价值修正的统一统计框架，以 Critic 估计与 MC 回报最小 MSE 线性融合为基础。核心技术贡献是 FixSCR 修正，通过从边际 MC 方差中减去状态价值结构方差来估计条件 MC 噪声 $\sigma_{G|s}^2 = \mathbb{E}[\text{Var}(G_t|s_t)]$ ——以全方差定律为依据。

HCGAE-PPO 在 GAE 累积之前将此修正应用于价值目标，衰减 Critic 初始化偏置。HCGAE-GRPO 将相同修正应用于归一化分母，恢复正确的优势信号量级。两种变体均通过 EV 追踪自适应，无需环境特定超参数，且仅修改优势计算组件。

在四个 MuJoCo 基准上的大规模实验表明一致改进，验证了 FixSCR 在方差膨胀最严重的稠密奖励环境中恢复 1.5–2× 优势量级的效果。

参考文献

Schulman et al., 2016

Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. 2016. High-dimensional continuous control using generalized advantage estimation. *ICLR 2016*.

Schulman et al., 2017

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. 2017. Proximal policy optimization algorithms. *arXiv:1707.06347*.

Shao et al., 2024

Shao, Z., et al. 2024. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv:2402.03300*.

Andrychowicz et al., 2021

Andrychowicz, O. M., et al. 2021. What matters for on-policy deep actor-critic methods? A large-scale study. *ICLR 2021*.

Ouyang et al., 2022

Ouyang, L., et al. 2022. Training language models to follow instructions with human feedback. *NeurIPS 2022*.

Espeholt et al., 2018

Espeholt, L., et al. 2018. IMPALA: Scalable distributed deep-RL with importance weighted actor-learner architectures. *ICML 2018*.

Munos et al., 2016

Munos, R., Stepleton, T., Harutyunyan, A., & Bellemare, M. 2016. Safe and efficient off-policy reinforcement learning. *NeurIPS 2016*.

Engstrom et al., 2020

Engstrom, L., Ilyas, A., Santurkar, S., Tsipras, D., Janoos, F., Rudolph, L., & Madry, A. 2020. Implementation matters in deep RL. *ICLR 2020*.

Engel et al., 2005

Engel, Y., Mannor, S., & Meir, R. 2005. Reinforcement learning with Gaussian processes. *ICML 2005*.

附录 A: Kalman 与贝叶斯等价性

Kalman 滤波。 在一维 Kalman 滤波中，先验 $\hat{x}_- = V_\phi(s_t)$ ，方差 $(P_- = \sigma_V^2)$ ，观测 $(z = G_t)$ ，观测噪声 $(R = \sigma_{G|s}^2)$ ：
$$K = \frac{P_-}{P_- + R} = \frac{\sigma_V^2}{\sigma_V^2 + \sigma_{G|s}^2} = \alpha^* \big|_{B=0}$$
 后验：
$$\hat{x}_+ = \hat{x}_- + K(z - \hat{x}_-)$$
 与 HCGAE 融合完全等价，其中 $(\alpha^* = K)$ 。

贝叶斯后验。 先验 $V^\pi \sim \mathcal{N}(V_\phi, \sigma_V^2)$ ，似然 $G_t | V^\pi \sim \mathcal{N}(V^\pi, \sigma_{G|s}^2)$ ，后验均值为：

$$\begin{aligned} & \mathbb{E}[V^\pi | G_t] \\ &= \frac{\sigma_{G|s}^{-2} \cdot V_\phi + \sigma_V^{-2} \cdot G_t}{\sigma_{G|s}^{-2} + \sigma_V^{-2}} = 1 - \alpha^* V_\phi + \alpha^* G_t = V^c_t \end{aligned}$$

确认 HCGAE 融合的贝叶斯解释。

附录 B: EV-增益近似的推导

由误差模型：
$$\mathrm{Var}(G_t) = \mathrm{Var}(V^\pi(s_t) + \epsilon_t) = \mathrm{Var}(V^\pi) + \sigma_{G|s}^2$$
 在近似 $\mathrm{Var}(V^\pi) \approx \sigma_V^2 + B^2$ (Critic 捕获方差结构) 下：
$$\mathrm{Var}(G_t) \approx \sigma_V^2 + B^2 +$$

$$\sigma_{G|s}^2 = \mathrm{Var}(G - V_\phi) \quad \text{因此} \quad 1 - \mathbf{EV} = \mathrm{Var}(G - V_\phi)$$
$$\mathrm{Var} G \approx \sigma_V^2 + B^2 + \sigma_{G|s}^2 / \sigma_V^2 + B^2 + \sigma_{G|s}^2 \cdot (\sigma_V^2 + B^2 / \sigma_V^2 + B^2 + \sigma_{G|s}^2) = \alpha^* \quad \blacksquare$$